

Probabilidad

Dr. Julio César Galindo López

Ley de los grandes números y el teorema central del límite

1. LA LEY DE LOS GRANDES NÚMEROS

Definición 1. (Convergencia en Probabilidad) Decimos que X_1, \dots, X_n, \dots una sucesión de variables aleatorias converge, *en probabilidad*, a $\mathbb{E}[X_i] = \mu$ si,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - \mu| > \varepsilon) = 0$$

para todo $\varepsilon > 0$

Teorema 2. (La ley débil de los grandes números) Sea X_1, \dots, X_n, \dots una sucesión de variables aleatorias independientes e idénticamente distribuidas tales que $\mathbb{E}[X_i] = \mu < +\infty$. Entonces,

$$\frac{X_1 + \dots + X_n}{n} \xrightarrow[n \rightarrow \infty]{} \mu$$

en probabilidad.

Usaremos la desigualdad de Chebyshev para probar el teorema 2 bajo la hipótesis (innecesaria) de que $\text{Var}(X_i) = \sigma^2 < \infty$.

1.1. Desigualdad de Chebyshev. Primero comencemos con la desigualdad de Markov.

Proposición 3. (Desigualdad de Markov) Sea X una variable aleatoria positiva con $\mathbb{E}[X] < \infty$, entonces

$$\mathbb{P}(X > a) \leq \frac{\mathbb{E}[X]}{a},$$

para todo $a > 0$.

Demostración. Consideremos a la variable aleatoria $\mathbf{1}_{\{X > a\}}$. Sabemos que $\mathbb{E}[\mathbf{1}_{\{X > a\}}] = \mathbb{P}(X > a)$. Ahora bien,

$$\begin{aligned} \mathbb{E}[X] &= \mathbb{E}[X \mathbf{1}_{\{X > a\}}] + \mathbb{E}[X \mathbf{1}_{\{X \leq a\}}] \\ &\geq a \mathbb{E}[\mathbf{1}_{\{X > a\}}] + \mathbb{E}[X \mathbf{1}_{\{X \leq a\}}] \\ &\geq a \mathbb{P}(X > a) \end{aligned}$$

en donde la desigualdad se sigue debido a que X es positiva (y por lo tanto $\mathbb{E}[X \mathbf{1}_{\{X \leq a\}}] > 0$).

Corolario 4. (Desigualdad de Chebyshev) Sea X una variable aleatoria con $\mathbb{E}[X] < \infty$ y $\text{Var}(X) < \infty$. Entonces,

$$\mathbb{P}(|X - \mathbb{E}[X]| > a) \leq \frac{\text{Var}(X)}{a^2},$$

para toda $a > 0$.

Demostración. Se tiene la siguiente igualdad de eventos

$$\{|X - \mathbb{E}[X]| > a\} = \{(X - \mathbb{E}[X])^2 > a^2\}.$$

Así, de la desigualdad de Markov,

$$\begin{aligned} \mathbb{P}(|X - \mathbb{E}[X]| > a) &= \mathbb{P}((X - \mathbb{E}[X])^2 > a^2) \\ &\leq \frac{\mathbb{E}[(X - \mathbb{E}[X])^2]}{a^2} \\ &= \frac{\text{Var}(X)}{a^2}. \end{aligned}$$

1.2. Demostración de la ley débil de los grandes números. Consideremos a la sucesión de variables aleatorias

$$\left\{ \bar{X}_n := \frac{X_1 + \cdots + X_n}{n} \right\}_{n \geq 1}.$$

Se tiene que:

$$\mathbb{E}[\bar{X}_n] = \frac{1}{n} \sum_{i=1}^n \mu = \mu$$

y además

$$\text{Var}[\bar{X}_n] = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{\sigma^2}{n}.$$

Por la desigualdad de Chebyshev 4,

$$\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}.$$

Finalmente,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) = 0,$$

lo que prueba el resultado.

Corolario 5. (Método Monte-Carlo) Sean U_1, \dots, U_n variables aleatorias independientes e idénticamente distribuídas sobre el intervalo $(0, 1)$. Sea $f : [0, 1] \rightarrow \mathbb{R}$ una función continua y acotada (por lo tanto integrable). Entonces, las variables aleatorias $f(U)_1, \dots, f(U)_n$ son independientes e idénticamente distribuídas y

$$\frac{f(U)_1 + \cdots + f(U)_n}{n} \xrightarrow{n \rightarrow \infty} \int_0^1 f(t) dt.$$

1.3. Ejemplos.

Ejemplo 6. Suponga que tomamos X_1, \dots, X_n, \dots variables aleatorias independientes uniformes sobre $(0, 1)$. Entonces, $\mathbb{E}[X_i] = \frac{1}{2}$, $\text{Var}(X_i) = \frac{1}{12}$. Entonces,

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow{n \rightarrow \infty} \frac{1}{2}$$

en probabilidad.

Ejemplo 7. Consideremos n lanzamientos independientes de un dado. Sea X_i el resultado del i -ésimo lanzamiento con $\mathbb{E}[X_i] = 7/2$. Entonces, $S_n = X_1 + \cdots + X_n$ es la suma de los primeros n lanzamientos. La ley de los grandes números nos dice que

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow{n \rightarrow \infty} \frac{7}{2}$$

Prueba el siguiente código:

```

1 #Librerías
2 import matplotlib.pyplot as plt
3 plt.rcParams["figure.figsize"] = (11, 5)
4 import random
5 import numpy as np
6 from scipy.stats import t, beta, lognorm, expon, gamma, uniform
7 from scipy.stats import gaussian_kde, poisson, binom, norm, chi2
8 from mpl_toolkits.mplot3d import Axes3D
9 from matplotlib.collections import PolyCollection
10 from scipy.linalg import inv, sqrtm
11

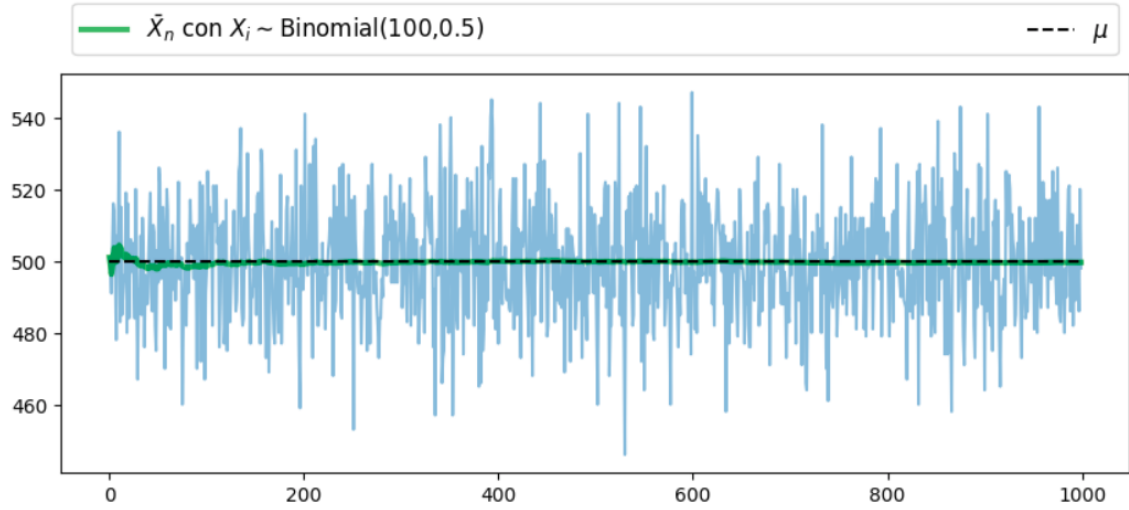
```

```

12 # tamaño
13 n = 100
14
15 # Colección de distribuciones
16 distributions = {"Binomial(100,0.5)": binom(1000, 0.5),
17 "poisson(4)": poisson(4),
18 "uniforme": beta(2, 2),
19 "beta(5, 1/2)": gamma(5, scale=2),
20 "exponencial con media 1": expon(1)}
21
22
23 num_plots = 3
24 fig, axes = plt.subplots(num_plots, 1, figsize=(10, 20))
25
26 bbox = (0., 1.02, 1., .102)
27 legend_args = {'ncol': 2,
28               'bbox_to_anchor': bbox,
29               'loc': 3,
30               'mode': 'expand'}
31 plt.subplots_adjust(hspace=0.5)
32
33 for ax in axes:
34     # Se eligen distribuciones
35     dist = random.choice(list(distributions.keys()))
36     distribution = distributions.pop(dist)
37
38     # Generamos las muestras
39     data = distribution.rvs(n)
40
41     # Medias muestrales (promedios)
42     sample_mean = np.empty(n)
43     for i in range(n):
44         sample_mean[i] = np.mean(data[:i+1])
45
46     ax.plot(list(range(n)), data, 'o', color='grey', alpha=0.5)
47     axlabel = '$\\bar{X}_n$ for $X_i \\sim$' + dist
48     ax.plot(list(range(n)), sample_mean, 'g-', lw=3, alpha=0.6, label=axlabel)
49     m = distribution.mean()
50     ax.plot(list(range(n)), [m] * n, 'k--', lw=1.5, label='$\\mu$')
51     ax.vlines(list(range(n)), m, data, lw=0.2)
52     ax.legend(**legend_args, fontsize=12)
53
54 plt.show()

```

Ejemplo 8. (El estimador de Kolmogorov-Smirnov es un estimador Monte.Carlo) Sea X_1, \dots, X_n, \dots una sucesión de variables aleatorias independientes e idénticamente distribuídas con función de distribución acumulada F . Sea $x \in \mathbb{R}$ un real fijo y defínase $Z_i = \mathbf{1}_{\{X_i \leq x\}}$ (note que las variables aleatorias Z_i son



independientes e idénticamente distribuidas). Así, por la ley de los grandes números,

$$F_n(x) \xrightarrow{n \rightarrow \infty} \mathbb{E}[Z_i] = F,$$

en probabilidad. Además, si $a < b$ son números reales y definimos

$$W_n(x) := \sum_{i=1}^n Z_i = \text{card}(\{i \in \{1, \dots, n\} : X_i \leq x\}),$$

$$\frac{W_n(b) - W_n(a)}{n} = \frac{\text{card}(\{i \in \{1, \dots, n\} : a < X_i \leq b\})}{n} \xrightarrow{n \rightarrow \infty} F(b) - F(a),$$

en probabilidad. Si X_1 admite densidad $f(x)$, por el teorema fundamental del cálculo,

$$\frac{W_n(b) - W_n(a)}{n} = \frac{\text{card}(\{i \in \{1, \dots, n\} : a < X_i \leq b\})}{n} \xrightarrow{n \rightarrow \infty} \int_a^b f(x) dx.$$

2. EL TEOREMA CENTRAL DEL LÍMITE

Teorema 9. Sea X_1, \dots, X_n, \dots una sucesión de variables aleatorias independientes e idénticamente distribuidas tales que $\mathbb{E}[X_i] = \mu < +\infty$ y $\text{Var}(X_i) = \sigma^2 < \infty$. Definamos a la siguiente sucesión de variables aleatorias $S_n = X_1 + \dots + X_n$ y tomemos su estandarización:

$$Z_n = \frac{S_n - n\mu}{\sqrt{n\sigma^2}}.$$

Entonces, para todo cualesquiera reales $a < b$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(a \leq Z_n \leq b) = \Phi(b) - \Phi(a),$$

en donde

$$\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx.$$


El principio del TCL es el siguiente:

- Obtener muestras aleatorias.
- Necesitamos remuestreo.
- Obtener la muestra de las medias.
- Realizar el histograma.

```

1 #Librerías
2 import numpy as np
3 import pandas as pd
4 import seaborn as sns
5
6
7 # Vamos a crear distintas muestras (100) y los acomodaremos en un panel
8 np.random.seed(1)
9
10 df = pd.DataFrame()
11
12 for i in range(1, 10001):
13     muestras_binomiales = np.random.binomial(10000, 0.6, 1000)
14     columnas = f"muestra {i}"
15     df[columnas]=muestras_binomiales
16
17 muestra_medias_binom = pd.DataFrame(df.mean(), columns = ["Muestra_medias_binomial"])
18 sns.distplot(muestra_medias_binom)

```



2.1. Ejemplos.

Ejemplo 10. El análisis de los viajes diarios muestra que el número de pasajeros por automóvil, X , es una variable aleatoria discreta con distribuciones idénticas e independientes, tales que $\mathbb{E}[X] = 1.2$ y $\text{Var}(X) = 1$. Estima la probabilidad de que, en una muestra de $n = 100$ automóviles, el número total de pasajeros es de 140 o menos.

Por lo tanto,

$$\mathbb{P}(S_n \leq 140) \approx \Phi(2) = 0.9772.$$

Ejemplo 11. Hay 100 personas en un avión. Sea X_i el peso (en kg) de la i -ésima persona en el avión. Supongamos que las variables aleatorias X_1, \dots, X_n son independientes e idénticamente distribuidas y $\mathbb{E}[X_i] = \mu = 170$ and $\text{Var}(X_i) = \sigma^2 = 30$. Estimemos la probabilidad de que el peso total de las personas en el avión exceda los 18,000 kg. Si S_{100} es la variable aleatoria que denota el peso total, entonces $S_{100} = X_1 + X_2 + \dots + X_{100}$. Tenemos $\mathbb{E}[S_{100}] = (100)(170) = 17000$. y $\text{Var}(S_{100}) = (100)(30)^2 = 90000$. Por el TCL

$$\begin{aligned}\mathbb{P}(S_{100} > 18000) &= \mathbb{P}\left(\frac{S_{100} - 17000}{300} > \frac{18000 - 17000}{300}\right) \\ &= \mathbb{P}\left(\frac{S_{100} - 17000}{300} > \frac{10}{3}\right) \\ &= 1 - \Phi\left(\frac{10}{3}\right) \\ &\approx 4.3 \times 10^{-4}.\end{aligned}$$

Ejemplo 12. Sean X_1, X_2, \dots, X_{25} variables aleatorias discretas independientes e idénticamente distribuidas con función de masa de probabilidades dada por

$$P_X(k) = \begin{cases} 0.6 & k = 1 \\ 0.4 & k = -1 \\ 0 & \text{otherwise} \end{cases}$$

Sea $S_n = X_1 + \dots + X_n$. Usando el TCL, estimemos $\mathbb{P}(4 \leq S_n \leq 6)$. Se tiene $\mathbb{E}[X_i] = \frac{1}{5}$ y $\mathbb{E}[X_i^2] = 1$. Por lo tanto, $\text{Var}(X_i) = 1 - \frac{1}{25} = \frac{24}{25}$. De esta forma, $\mathbb{E}[S_n] = 5$ y $\text{Var}(S_n) = 24$. Así,

$$\begin{aligned}\mathbb{P}(4 \leq S_n \leq 6) &= \mathbb{P}\left(\frac{4 - 5}{2\sqrt{6}} \leq \frac{S_n - 5}{2\sqrt{6}} \leq \frac{6 - 5}{2\sqrt{6}}\right) \\ &= \mathbb{P}\left(-\frac{1}{2\sqrt{6}} \leq Z_n \leq \frac{1}{2\sqrt{6}}\right) \\ &\approx \Phi(0.2041) - \Phi(-0.2041) \\ &= 2\Phi(0.2041) - 1 \\ &\approx 0.16172\end{aligned}$$

Ejemplo 13. Sean X_1, X_2, \dots, X_n variables aleatorias independientes e idénticamente distribuidas exponencialmente con $\lambda = 1$. Sea

$$\bar{X}_n = \frac{X_1 + \dots + X_n}{n}$$

Veamos qué tan grande debe ser n para asegurar que

$$\mathbb{P}(0.9 \leq \bar{X} \leq 1.1) \geq 0.95$$

Sea $S_n = X_1 + \dots + X_n$, so $\bar{X} = \frac{Y}{n}$. Tenemos que,

$$\mathbb{E}[X_i] = 1, \quad \text{Var}(X_i) = 1$$

De aquí que, $\mathbb{E}[S_n] = n\mathbb{E}[X_i] = n$ y $\text{Var}(X_i) = n$.

Por lo tanto,

$$\begin{aligned}\mathbb{P}(0.9 \leq \bar{X}_n \leq 1.1) &= \mathbb{P}\left(0.9 \leq \frac{S_n}{n} \leq 1.1\right) \\ &= \mathbb{P}(0.9n \leq S_n \leq 1.1n) \\ &= \mathbb{P}\left(\frac{0.9n - n}{\sqrt{n}} \leq \frac{S_n - n}{\sqrt{n}} \leq \frac{1.1n - n}{\sqrt{n}}\right) \\ &= \mathbb{P}(-0.1\sqrt{n} \leq Z_n \leq 0.1\sqrt{n})\end{aligned}$$

Por el TCL

$$\begin{aligned}\mathbb{P}(0.9 \leq \bar{X} \leq 1.1) &\approx \Phi(0.1\sqrt{n}) - \Phi(-0.1\sqrt{n}) \\ &= 2\Phi(0.1\sqrt{n}) - 1\end{aligned}$$

Necesitamos que $2\Phi(0.1\sqrt{n}) - 1 \geq 0.95$ o, equivalentemente, $\Phi(0.1\sqrt{n}) \geq 0.975$

Por lo tanto,

$$\begin{aligned}0.1\sqrt{n} &\geq \Phi^{-1}(0.975) = 1.96 \\ \sqrt{n} &\geq 19.6 \\ n &\geq 384.16\end{aligned}$$

De esta manera, podemos tomar $n \geq 385$.